段冰

+86 18510840710 | reese_duan@163.com | github.com/imReese

求职意向 大模型推理引擎 / 推理服务 | 北京



工作经历

百度 · AI 计算 / 训推引擎组 软件工程师（大模型推理引擎） 2025.06 - 至今

负责百度智能云千帆 MaaS 平台 Attention Store 与 SGLang 的研发、性能优化及工程化，支撑多模型在线推理服务。

Attention Store（AS）

- 完善全局缓存索引的构建与同步、分层命中查询和预读接口，支持缓存感知调度与复用。
- 完成 AS 缓存与 SGLang 统一 radix 树的合并迁移，完善缓存读写和前缀复用，实际业务流量下缓存命中率达 90%+；实现 PP 跨 Agent 缓存协同，支持缓存组生命周期管理、共同可读前缀、状态检查点、读取租约及失败回滚。

SGLang

- **模型工程化与执行优化**：完成多模型适配、精度验证及 TP、多 DP、PP、DCP 部署；优化 Prefill 阶段的状态跟踪与执行计划，跨层复用元数据，减少主机与设备间的同步及重复分配。
- **调度与资源管理**：在 Mamba 请求准入时，按实际缺口预留状态槽位与缓冲区，缓存回载后再次检查容量；协调 PP 请求取消、调度重放、KV 传输完成与资源回收的执行顺序。

华为云 · 竖亥实验室 计算机体系结构研究工程师 2023.07 - 2024.07

- 面向 MySQL、Redis 等云负载，基于 perf、Intel Pin 构建指令流分析工具；在 ChampSim 中实现并验证 TLB 动态调度策略，仿真中 IPC 提升 6%，已申请发明专利。
- 分析指令级并行度，与海思、openEuler 协作验证新一代鲲鹏 SMT 优化策略，单核吞吐量提升 8%。

华为数据存储产品线 · 基础设施开发部 软件开发工程师 2022.05 - 2023.07

- 负责分布式存储控制面 Cluster Manager 的研发，包括基于 Paxos 的 CM 自身选主与客户端选主、DPC 客户端管理及集群生命周期管理；通过异步消息队列重构组件通信，降低模块耦合。

独立项目

SGLang-rs · Rust 推理引擎 Rust / gRPC / CUDA 2026.05 - 至今

- 解耦调度、执行与路由，兼容 OpenAI API 并提供 gRPC 服务；在 macOS、Ubuntu Linux 上验证 Qwen3.5-0.8B 完整模型的 CPU 推理，支持对话和流式输出。通过 Qwen3 CPU 参考测试验证 P/D 数值一致性及 KV 损坏检测；已接入 CUDA/Mooncake，GPU 推理与 P/D 网络传输尚待验证。

NexusKV · 跨引擎状态复用 Go / Rust / Python 2025.04 - 至今

- 解耦复用判断与数据传输，用 Rust 实现最长前缀匹配，确定可复用与待计算部分；经 PyO3 提供 Python 接口，主机内存存储设有容量上限，通过身份隔离、缓存淘汰及后端不支持时的回退测试。

Locus · 状态感知的推理控制面 Rust / Axum 2026.08 - 至今

- 根据模型能力、实例负载和可复用状态的位置选择执行实例，将调度规划与执行解耦；执行前重新校验计划，处理资源预留、回退及取消后的清理；通过 OpenAI/Anthropic 官方 SDK 和本地模拟后端，验证流式输出和客户端断连后取消请求的传递。

开源讨论：向 SGLang 提出 HiCache 数据面与调度器解耦 RFC（#37372）。

技术技能

推理系统：熟悉 SGLang、vLLM、DeepInfer，了解 Mooncake Store。
编程与工程：C/C++、Python、Go、Rust、Shell；Linux、Docker、Kubernetes、Git、CMake。

教育背景

南京大学 环境工程 · 学士 GPA 4.2/5.0 2017.09 - 2021.06