段冰

+86 18510840710 | reese_duan@163.com | github.com/imReese

求职意向 大模型推理引擎 / 推理服务 | 北京



工作经历

百度 · AI 计算 / 训推引擎组 软件工程师（大模型推理引擎） 2025.06 - 至今

负责百度智能云千帆 MaaS 推理引擎研发与性能优化，以及 SGLang 生产部署与工程化。

- **状态管理**：完成 Attention Store（AS）缓存与统一 radix 树的合并迁移，建成面向多模型、多并行部署的缓存存储子系统，解决多并行、多模态场景中的稳定性问题。
- **缓存复用**：优化 AS 读写与前缀复用，实际业务流量下缓存命中率达 90%+，提升 Prefill 吞吐；团队方案支持流水线并行下的 L3 存储接入。
- **多模型与并行部署**：完成模型引擎适配与精度验证，开展 TP、多 DP、PP、DCP 等并行配置下的部署；完善可观测性接口，定位并解决并行部署中的稳定性问题。
- **运行时性能分析**：针对定长压测与真实流量的性能差异，分析请求长度、执行后端选择和缓存复用收益；承担 Prefill/EPD 与约束解码相关优化。
- **传输与计算重叠**：将主机侧 KV cache 操作、H2D/D2H 传输与 GPU 批次执行组织为异步流程，结合 Mooncake TransferEngine 分析并优化 KV 传输路径。

华为云 · 竖亥实验室 计算机体系结构研究工程师 2023.07 - 2024.07

- 基于 perf、Intel Pin 构建云负载指令流分析工具，在 ChampSim 中实现并验证 TLB 调度策略，IPC 提升 6%，已申请发明专利。
- 分析指令级并行度，协同海思、openEuler 验证鲲鹏 SMT 优化策略，单核吞吐量提升 8%。

华为数据存储产品线 · 基础设施开发部 软件开发工程师 2022.05 - 2023.07

- 负责基于 Paxos 的 Cluster Manager 选主与集群生命周期管理；重构组件通信模型，以异步消息队列解耦模块间通信，将单集群规模从 128 扩展至 256 节点。
- 完善模块间参数校验与命令注入防护；定位并解决 20+ 生产高优先级问题。

独立项目

SGLang-rs · Rust 轻量级推理引擎 Rust / gRPC / CUDA 2026.05 - 至今

- 使用 Rust 实现轻量级 LLM 推理引擎，串联模型加载、调度、Prefill/Decode 与前缀缓存复用，提供兼容 OpenAI 的 HTTP 接口。支持 macOS/Linux CPU 本地运行，在 Linux 验证 Qwen2.5-0.5B-Instruct 真实模型推理；接入 CUDA 执行与 Mooncake KV 传输，支持 P/D 分离。

NexusKV · 跨引擎状态复用 Go / Rust / Python 2025.04 - 至今

- 面向跨引擎状态复用，将复用判断与传输后端解耦；实现 Rust 前缀索引与部分复用规划，经 PyO3 接入 Python，提供有界 Host DRAM 存储；通过租户隔离、LRU 淘汰和连接器回退测试。

Locus · 状态感知的推理控制面 Rust / Axum 2026.08 - 至今

- 实现跨实例规划与执行分离，按模型能力、负载与缓存位置选择实例，支持失败回退和资源释放；提供 OpenAI/Anthropic 接口，通过官方 SDK 在本地模拟后端上验证流式响应与取消。

架构设计建议：向 SGLang 提出缓存数据面与 Scheduler 解耦 RFC（#37372），另提出共享缓存传输类型的模块边界调整建议（#38889）。

技术技能

推理系统：熟悉 SGLang、vLLM、DeepInfer，了解 Mooncake Store。
编程与工程：C/C++、Python、Go、Rust、Shell；Linux、Docker、Kubernetes、Git、CMake。

教育背景

南京大学 环境工程 · 学士 GPA 4.2/5.0 2017.09 - 2021.06