段冰 Reese

+86 18510840710 | reese_duan@163.com | github.com/imReese | 技术博客

求职方向 AI Infra / 大模型推理引擎 / 后端系统

聚焦大模型推理运行时、模型状态缓存与传输计算重叠。此前从事 CPU 微架构性能分析和分布式存储控制面开发。

工作经历

百度 · AI 计算 / 训推引擎组 2025.06 - 至今

软件工程师（大模型推理引擎）

负责 SGLang 生产级部署与工程化，支撑大规模集群推理服务；补齐引擎可观测性接口，推进核心稳定性问题闭环。

- **缓存索引与存储子系统**：完成 Attention Store（AS）缓存与统一 radix 树的合并迁移，建成 AS 存储子系统；修复多并行、多模态场景的稳定性问题。
- **模型适配与并行部署**：完成 Kimi 系列引擎适配，处理 PP 部署适配与稳定性问题；支撑 GLM、DeepSeek 系列落地与精度验证。团队 AS 方案支持 KDA 状态及 PP 下的 L3 存储接入。
- **缓存读写与复用收益**：优化 Attention Store 读写与前缀复用，提升缓存命中率和 Prefill 吞吐。
- **传输与 GPU 批次执行**：组织主机侧执行、KV cache 操作与 GPU 批次执行的异步流水，实现 H2D、D2H 传输与计算重叠；结合 Mooncake TransferEngine 分析与优化 KV 传输路径。
- **Prefill 与运行时优化**：承担 Prefill/EPD 与约束解码相关优化；对比定长压测与真实流量，分析请求长度和 KDA 后端选择对 Prefill 性能及缓存复用收益的影响。
- **分层缓存架构验证**：探索 LMCache 与 KV manager 的分层架构，搭建 LMCache 服务端并完成方案可行性验证。

华为云 · 竖亥实验室 2023.07 - 2024.07

计算机体系结构研究工程师

- **负载分析**：基于 perf 和 Intel Pin 构建低开销指令流分析工具，提取 MySQL、Redis 等云服务负载的指令流特征，为微架构方案验证提供依据。
- **微架构验证**：结合指令流特征与 ChampSim 仿真验证 CPU 方案，TLB 命中率提升 30%，IPC 提升 6%；相关方案已申请发明专利。
- **软硬协同**：与海思、openEuler 团队协作验证鲲鹏 CPU 性能优化方案，单核吞吐量提升 8%。

华为数据存储产品线 · 基础设施开发部 2022.05 - 2023.07

软件开发工程师

- **控制面开发**：负责分布式存储 Cluster Manager，覆盖服务选主、客户端选主与集群生命周期管理。
- **异步化与规模扩展**：通过异步消息队列和模块解耦，将单集群支持节点数从 128 扩展至 256，资源初始化效率提升 40%。
- **可靠性建设**：主导 200+ 接口自动化测试与安全加固，分支覆盖率 90%+；定位并解决 20+ 生产环境高优先级问题。

段冰 Reese

AI Infra / 大模型推理引擎

独立系统项目

以下项目处于研发验证阶段；本地功能与协议验证不等同于生产部署验收。

SGLang Rust Runtime 2026.05 - 至今

github.com/imReese/sglang-rs Rust / gRPC / CUDA

- **调度与就绪门控**：实现按未缓存 token 预算组建 Prefill 批次、页对齐前缀复用与 KV 就绪门控；P/D Decode 在 KV 就绪后派发，异步 Prefill 页在传输完成后发布。
- **统一物理 KV 页**：CUDA 执行与 Mooncake 注册使用同一 page-major KV pool；以 RAII 管理注册与设备内存生命周期，先注销再释放。失败时回收未发布页，中止时取消传输批次。
- **执行后端**：实现 Qwen2/3 共享 dense decoder、F32 CPU 参考与 BF16 CUDA 执行路径，接入 cuBLAS GEMM 与 GQA paged attention。

NexusKV 2025.04 - 至今

github.com/imReese/NexusKV Go / Rust / Python

- **状态语义与匹配**：以版本化描述符区分租户、模型修订与布局；用 Rust 实现精确匹配、最长前缀匹配、部分命中计划和并发 copy-on-write 更新，经 PyO3 暴露给 Python 规划层。
- **载荷与消费边界**：实现带容量上限和身份隔离的 Host DRAM 存储；以 payload handle、transfer session 区分状态发现、传输过程与运行时消费，保留引擎对最终接纳和内存分配的控制权。
- **适配与协议验证**：提供生命周期感知的 SGLang/vLLM 适配接口及 Locus 的 lookup/estimate/materialize HTTP 桥接；验证确定性动作选择、回退、生命周期协议和本地 HTTP 传输。

Locus

github.com/imReese/Locus Rust / Axum

- **策略感知放置**：实现 OpenAI/Anthropic 兼容入口、租户加权准入和能力过滤，结合模型语义、计算负载与可复用状态成本生成 PlacementPlan。
- **执行编排**：分离 Planner 与 PlanExecutor，执行重新校验、目标预留、可选状态导入协调、任务提交、有界回退与清理；使用官方 SDK 和确定性引擎验证本地 HTTP 协议及编排链路。

架构设计建议

向 SGLang 提出缓存数据面与 Scheduler 分离的 RFC（#37372），讨论元数据所有权、GPU 内存 IPC 与生命周期；另建议将共享缓存传输类型迁到中立模块并兼容导出（#38889）。

技术技能

编程语言：C/C++、Python、Go、Rust、Shell
性能与系统：Linux、perf、Intel Pin、ChampSim、gdb、Paxos
工程工具：Docker、Kubernetes、Prometheus、Grafana、Git、CMake

教育背景

南京大学 2017.09 - 2021.06

环境工程 · 学士 GPA 4.2/5.0