段冰

+86 18510840710 | reese_duan@163.com | github.com/imReese

求职意向 大模型推理引擎 / 推理服务 | 北京



工作经历

百度 · AI 计算 / 训推引擎组 软件工程师（大模型推理引擎） 2025.06 - 至今

面向百度智能云千帆 MaaS 多模型在线推理服务，负责 Attention Store 与 SGLang 的研发、性能优化及生产工程化。

Attention Store（AS）

- 完善全局缓存索引构建与同步、分层命中查询及预读接口，支撑 cache-aware 调度与缓存复用。
- 完成 AS 缓存与 SGLang 引擎侧统一 radix 树的合并迁移，完善读写与前缀复用，实际业务流量下缓存命中率达 90%+；实现 PP 跨 Agent 缓存协同，覆盖缓存组生命周期、共同可读前缀、状态检查点、读取租约与失败回滚。

SGLang

- **模型工程化与执行优化**：完成多模型适配、精度验证及 TP、多 DP、PP、DCP 部署；优化 Prefill 状态跟踪与执行计划，复用跨层元数据，减少主机与设备同步及重复分配。
- **调度与资源管理**：在 Mamba 准入阶段按实际缺口预留状态与缓冲区，缓存回载后复核容量；完善 PP 请求取消、调度重放、KV 传输完成与资源回收的协同时序。

华为云 · 竖亥实验室 计算机体系结构研究工程师 2023.07 - 2024.07

- 面向 MySQL、Redis 等云负载，基于 perf、Intel Pin 构建指令流分析工具；在 ChampSim 中实现并验证 TLB 动态调度策略，仿真 IPC 提升 6%，已申请发明专利。
- 分析指令级并行度，协同海思、openEuler 验证新一代鲲鹏 SMT 优化策略，单核吞吐量提升 8%。

华为数据存储产品线 · 基础设施开发部 软件开发工程师 2022.05 - 2023.07

- 负责分布式存储控制面 Cluster Manager，覆盖基于 Paxos 的 CM 自身选主与客户端选主、DPC 客户端管理及集群生命周期；以异步消息队列重构组件间通信、解耦模块。

独立项目

SGLang-rs · Rust 推理运行时原型 Rust / gRPC / CUDA 2026.05 - 至今

- 分离调度与执行，串联模型加载、前缀缓存和 Prefill/Decode；在 Linux 跑通 Qwen2.5-0.5B-Instruct CPU 推理。适配 Qwen3.5 混合注意力文本模型，通过 CPU 合成权重测试；以 Qwen3 CPU 参考测试验证 P/D 数值一致性与 KV 损坏检测。实现 CUDA/Mooncake P/D 接入，GPU 链路待验收。

NexusKV · 跨引擎状态复用 Go / Rust / Python 2025.04 - 至今

- 分离复用判定与传输执行，以 Rust 实现最长前缀匹配，划分可复用与待计算范围；经 PyO3 接入 Python，配套有界 Host DRAM 存储，通过身份隔离、容量淘汰与能力不足回退测试。

Locus · 状态感知的推理控制面 Rust / Axum 2026.08 - 至今

- 面向跨实例放置与执行控制，按模型能力、负载和状态位置规划目标；分离规划与执行，执行前重校验，管理资源预留、回退与取消清理；通过 OpenAI/Anthropic 官方 SDK 和本地模拟后端验证流式响应与断连后的取消传播。

开源讨论：向 SGLang 提出 HiCache 数据面与调度器解耦 RFC（#37372）。

技术技能

推理系统：熟悉 SGLang、vLLM、DeepInfer，了解 Mooncake Store。
编程与工程：C/C++、Python、Go、Rust、Shell；Linux、Docker、Kubernetes、Git、CMake。

教育背景

南京大学 环境工程 · 学士 GPA 4.2/5.0 2017.09 - 2021.06