段冰

+86 18510840710 | reese_duan@163.com | github.com/imReese

求职意向 大模型推理引擎 / 推理服务 | 北京



工作经历

百度 · AI 计算 / 训推引擎组 软件工程师（大模型推理引擎） 2025.06 - 至今

负责百度智能云千帆 MaaS 推理引擎研发与性能优化，以及 SGLang 生产部署与工程化。

- **缓存整合与复用**：完成 Attention Store（AS）与统一 radix 树的合并迁移，优化缓存读写与前缀复用；实际业务流量下缓存命中率达 90%+。
- **流水线缓存协同**：实现 PP 缓存组注册与生命周期管理，协调跨 Agent 共同可读前缀及状态检查点，处理读取租约与失败回滚。
- **调度与资源正确性**：修复 PP 请求取消与调度重放不一致，调整 KV 传输完成判断与资源回收时序；按实际缺口预留 Mamba 状态与缓冲区，缓存回载后复核容量。
- **性能分析与部署**：完成多模型适配、精度验证及 TP、多 DP、PP、DCP 部署；对照定长压测与真实流量，分析请求长度、执行后端与缓存复用带来的性能差异。

华为云 · 竖亥实验室 计算机体系结构研究工程师 2023.07 - 2024.07

- 面向 MySQL、Redis 等云负载，基于 perf、Intel Pin 构建指令流分析工具；在 ChampSim 中实现并验证 TLB 动态调度策略，仿真 IPC 提升 6%，已申请发明专利。
- 分析指令级并行度，协同海思、openEuler 验证新一代鲲鹏 SMT 优化策略，单核吞吐量提升 8%。

华为数据存储产品线 · 基础设施开发部 软件开发工程师 2022.05 - 2023.07

- 负责分布式存储控制面 Cluster Manager，覆盖 DPC 客户端管理、Paxos 选主与集群生命周期；以异步消息队列重构组件通信、解耦模块。
- 通过模块间参数校验与输入过滤防护命令注入；定位并解决 20+ 生产高优先级问题。

独立项目

SGLang-rs · Rust 推理运行时原型 Rust / gRPC / CUDA 2026.05 - 至今

- 使用 Rust 实现推理运行时，分离调度与执行，串联模型加载、Prefill/Decode 与前缀缓存；在 Linux 跑通 Qwen2.5-0.5B-Instruct CPU 推理。实现 CUDA/Mooncake P/D 接入，GPU 链路待验收。

NexusKV · 跨引擎状态复用 Go / Rust / Python 2025.04 - 至今

- 面向跨引擎状态复用，将复用判断与传输执行分离；实现 Rust 最长前缀匹配与部分复用规划，经 PyO3 接入 Python，配套有界 Host DRAM 存储；测试覆盖身份隔离、容量淘汰及能力不足回退。

Locus · 状态感知的推理控制面 Rust / Axum 2026.08 - 至今

- 将跨实例放置规划与执行分离，按模型能力、负载和状态位置选择目标；执行前重校验，处理资源预留、回退与取消清理；通过官方 SDK 与本地模拟后端验证流式响应和取消传播。

开源讨论：向 SGLang 提出 HiCache 数据面与调度器解耦 RFC（#37372）。

技术技能

推理系统：熟悉 SGLang、vLLM、DeepInfer，了解 Mooncake Store。
编程与工程：C/C++、Python、Go、Rust、Shell；Linux、Docker、Kubernetes、Git、CMake。

教育背景

南京大学 环境工程 · 学士 GPA 4.2/5.0 2017.09 - 2021.06