

段冰

+86 18510840710 reese_duan@163.com Github/imReese



求职方向: AI Infra / 大模型推理引擎 / 后端系统

工作经历

- 百度 - AI 计算 / 训推引擎组 2025.06 - 至今
软件工程师 (大模型推理引擎)
 - SGLang 企业级工程化: 负责 SGLang 的生产级部署与工程化, 支撑万卡级集群的大模型推理服务。
 - 推理系统优化: 围绕 runtime 调度、KV Cache、Prefill/Decode 解耦、Mooncake TransferEngine 和异构 backend 开展性能分析与优化。
 - 性能与稳定性: 面向大规模部署分析吞吐、时延、内存与 KV 传输链路, 定位 runtime 和 backend 瓶颈。
- 华为云 - 竖亥实验室 2023.07 - 2024.07
计算机体系结构研究工程师
 - 性能工具与 workload 分析: 基于 perf 和 Intel Pin 构建低开销指令流分析工具, 覆盖 MySQL、Redis 等云服务负载。
 - 体系结构优化: 结合指令流特征与 ChampSim 仿真验证 CPU 微架构方案, TLB 命中率提升30%, IPC 提升6%, 相关方案已申请发明专利。
 - 软硬协同验证: 与海思、openEuler 团队协作验证鲲鹏 CPU 性能优化方案, 单核吞吐量提升8%。
- 华为数据存储产品线 - 基础设施开发部 2022.05 - 2023.07
软件开发工程师
 - 控制面 CM: 负责分布式存储控制面 Cluster Manager, 覆盖服务选主、客户端选主与集群生命周期管理。
 - 规模扩展: 通过异步消息队列与模块解耦, 将单集群支持节点数从 128 扩展至 256, 资源初始化效率提升40%。
 - 工程可靠性: 主导 200+ 接口自动化测试与安全加固, 分支覆盖率90%+, 并解决 20+ 生产环境高优先级问题。

教育背景

- 南京大学 2017.09 - 2021.06
学士 环境工程 GPA: 4.2/5.0
 - 核心课程: 计算机组成原理、数据结构、操作系统、计算机网络、计算机体系结构
 - 相关课程: 线性代数、概率论与数理统计、算法设计与分析

</> 个人项目

- SGLang Rust Runtime 2026.05 - 至今
 <https://github.com/imReese/sglang-rs> Rust, gRPC
 - 构建独立 Rust runtime, 覆盖 request lifecycle、gRPC router、scheduler、prefix cache 与 KV page allocation。
 - 面向 PD disaggregation 设计 Mooncake KV transfer 边界, 覆盖 bootstrap、readiness、polling 与 descriptor 校验。
- NexusKV 2025.04 - 至今
 <https://github.com/imReese/NexusKV> Go, Rust, Python
 - 将早期 Go prototype 演进为 LLM KV Cache 平台, 拆分 control plane、data plane 与 engine adapter。
 - 推进 versioned state descriptor、Rust prefix reuse index 及 SGLang/vLLM connector, 并建设可靠性与 benchmark 框架。

技能

- 大模型推理引擎、AI Infra 与后端系统工程
- 编程语言: C/C++、Python、Go、Shell、Rust
- 推理系统: SGLang、KV Cache、Mooncake TransferEngine、gRPC、调度与异构后端
- 系统与基础设施: Linux、Paxos、Docker、Kubernetes、Prometheus、Grafana、perf、gdb、Git、CMake